



Projet Business Intelligence

ETL Dual Source - Integration de donnees heterogenes

SQL Server + Microsoft Access → Data Warehouse Unifie

Etudiant : BOUMEDIENE Noufel

Formation : Cyber Security Engineering - 3rd Year

Etablissement : USTHB - Faculte d Informatique

Module : Technologies Business Intelligence

Decembre 2025

Sommaire

1. Introduction

2. Contexte et Problematique

3. Architecture du Projet

4. Processus ETL

5. Data Warehouse - Schema en Etoile

6. Fusion des Sources de Donnees

7. Indicateurs Cles de Performance

8. Tableau de Bord et Visualisations

9. Choix Techniques

10. Conclusion et Perspectives

1. Introduction

Ce rapport presente le projet de Business Intelligence (BI) realise in the context of the **Business Intelligence Technologies** module for 3rd Year **Cyber Security Engineering** a l'Universite des Sciences et de la Technologie Houari Boumediene (USTHB).

Le projet consiste en la conception et l'implementation d'une solution BI complete basee sur la base de donnees **Northwind**, avec une particularite majeure : l'extraction et la fusion de **deux sources de donnees heterogenes** :

- **SQL Server** - Base de donnees Northwind (source primaire)

- **Microsoft Access** - Base de données Northwind 2012 (source secondaire)

Ce projet répond à une problématique réelle dans le domaine de la Business Intelligence : comment intégrer des données provenant de systèmes différents, avec des schémas hétérogènes, des formats variés, et des incohérences potentielles, dans un entrepôt de données unifié permettant des analyses décisionnelles pertinentes.

Objectifs du projet :

- Développer un pipeline ETL (Extract, Transform, Load) robuste
- Gérer l'intégration de sources multiples avec réconciliation des données
- Implémenter un Data Warehouse en schéma étoile
- Calculer et suivre les indicateurs clés de performance (KPIs)
- Produire des visualisations et tableaux de bord analytiques

2. Contexte et Problematique

2.1. Contexte general

Dans le monde moderne de l'entreprise, les donnees sont dissipees dans des systemes heterogenes : ERP, CRM, applications metiers, bases de donnees relationnelles, fichiers Excel, etc. Chaque systeme possede son propre schema de donnees, ses propres conventions de nommage, et ses propres cycles de mise a jour.

La base de donnees **Northwind** est un exemple classique utilise dans l'enseignement de la BI. Elle represente les operations commerciales d'une entreprise de vente de produits alimentaires, avec des donnees sur les clients, les produits, les commandes, les employes, etc.

Pour ce projet, nous disposons de deux versions de cette base de donnees :

Source	Type	Version	Caracteristiques
SQL Server	SGBD Relationnel	Northwind classique	Donnees recentes, schema standard
Microsoft Access	Base de donnees locale	Northwind 2012	Schema different, donnees potentiellement obsoletes

2.2. Problematique

La problematique principale de ce projet est la suivante :

Problematique : Comment integrer efficacement des donnees provenant de sources heterogenes (SQL Server et Microsoft Access) presentant des differences de schema, de format et de contenu, afin de construire un Data Warehouse coherent permettant des analyses decisionnelles fiables ?

Les defis specifiques incluent :

- **Schemas differents** : Les colonnes ne portent pas les memes noms entre les deux sources (ex: ID vs CustomerID)

- **Incoherences de donnees** : Prix differents, employes manquants, produits non marques comme discontinues
- **Conflits de priorite** : Quelle source prendre en cas de contradiction ?
- **Traçabilite** : Comment identifier l'origine de chaque enregistrement ?
- **Performance** : Comment optimiser le processus d'integration ?

3. Architecture du Projet

L architecture du projet suit le pattern ETL (Extract, Transform, Load) adapte aux sources multiples. Elle se compose de trois couches principales :




Figure 1 : Architecture ETL avec integration de sources heterogenes

3.1. Couche des Sources

La couche source comprend deux systemes de stockage distincts :

Source 1 : SQL Server Northwind

- Base de donnees relationnelle complete
- Schema standard avec tables : Customers, Products, Orders, Order Details, Employees

- Donnees considerees comme reference (priorite en cas de conflit)
- Connectee via ODBC Driver 17 for SQL Server

Source 2 : Microsoft Access Northwind 2012

- Base de donnees locale (.accdb)
- Schema different avec mapping necessaire
- Peut contenir des donnees obsoletes ou manquantes
- Connectee via Microsoft Access Driver

3.2. Couche de Transformation

Cette couche est le coeur du processus ETL. Elle effectue les operations suivantes :

- **Extraction** : Recuperation des donnees des deux sources
- **Mapping de schema** : Harmonisation des noms de colonnes
- **Nettoyage** : Gestion des valeurs manquantes et incoherentes
- **Fusion** : Union des donnees avec deduplication
- **Resolution de conflits** : SQL Server prioritaire sur Access
- **Creation du schema etoile** : Dimensions et faits

3.3. Couche de Stockage

Les donnees transformees sont stockees dans :

- **Data Warehouse SQLite** : Base de donnees locale pour les requetes
- **Fichiers CSV** : Export pour analyse et backup
- **Schemas etoiles** : Tables de dimensions et table de faits

4. Processus ETL

4.1. Extraction (Extract)

La phase d'extraction récupère les données des deux sources de manière parallèle. Le système utilise des connecteurs ODBC pour accéder aux bases de données.

Gestion des indisponibilités

En cas d'indisponibilité d'une source, le système bascule automatiquement vers des fichiers CSV de secours, simulant ainsi les variations entre les sources.

Tables extraites

Table	SQL Server	Access 2012	Statut
Customers	91 clients	29 clients uniques	✓ Fusionne
Products	77 produits	19 produits uniques	✓ Fusionne
Employees	9 employes	9 employes	✓ Fusionne
Orders	830 commandes	48 commandes uniques	✓ Fusionne
Order Details	2 155 lignes	58 lignes	✓ Fusionne
Categories	8 categories	8 categories	✓ Fusionne
Suppliers	29 fournisseurs	0 fournisseur	✓ SQL Server
Shippers	3 transporteurs	3 transporteurs	✓ Fusionne

4.2. Transformation (Transform)

La phase de transformation est la plus complexe. Elle comprend plusieurs étapes :

4.2.1. Mapping de schema

La base Access 2012 utilise des noms de colonnes différents. Le mapping suivant est appliqué :

Table	Access 2012	SQL Server
Customers	ID	CustomerID
	Company	CompanyName
	Last Name / First Name	ContactName
Products	Product Name	ProductName
	List Price	UnitPrice
Orders	Order ID	OrderID
	Shipping Fee	Freight

4.2.2. Gestion des incohérences

Le système gère automatiquement les différences entre les sources :

Incohérence détectée	Stratégie de résolution
Employés manquants dans Access	Union des deux sources, SQL Server prioritaire
Prix différents (5% moins cher dans Access)	SQL Server (plus récent) prend la priorité
Clients manquants	Union avec déduplication par CustomerID
Produits discontinués	État SQL Server conserve
Commandes manquantes	Union avec déduplication par OrderID

4.2.3. Ajout de traçabilité

Un champ `DataSource` est ajouté à chaque enregistrement pour identifier son origine :

- `DataSource = 'SQLServer'` : Donnée provenant de SQL Server
- `DataSource = 'Access'` : Donnée provenant de Microsoft Access

4.3. Chargement (Load)

La phase de chargement alimente le Data Warehouse avec les données transformées :

- Creation des tables de dimensions (Dim_*)
- Creation de la table de faits (Fact_Sales)
- Export vers SQLite pour le stockage
- Export vers CSV pour l'analyse et le backup
- Generation de vues analytiques pre-agregees

5. Data Warehouse - Schema en Etoile

Le Data Warehouse est implemente selon le modele en etoile (Star Schema), recommande pour les analyses OLAP. Ce modele offre un bon equilibre entre performance et simplicite de requetes.




Figure 2 : Schema en etoile du Data Warehouse Northwind

5.1. Tables de Dimensions

Les dimensions representent les axes d analyse. Elles contiennent des attributs descriptifs utilises pour filtrer et regrouper les donnees.

Dim_Time

Dimension temporelle avec hierarchie : Année > Trimestre > Mois > Jour

- **TimeKey** : Cle de substitution (PK)
- **Date** : Date complete
- **Year** : Année
- **Quarter** : Trimestre (1-4)
- **Month** : Mois (1-12)
- **MonthName** : Nom du mois
- **DayOfWeek** : Jour de la semaine
- **IsWeekend** : Indicateur weekend

Dim_Customers

Dimension clients avec hierarchie géographique : Pays > Région > Ville

- **CustomerKey** : Cle de substitution (PK)
- **CustomerID** : Cle naturelle
- **CompanyName** : Nom de l'entreprise
- **ContactName** : Nom du contact
- **City** : Ville
- **Region** : Région
- **Country** : Pays
- **DataSource** : Origine de la donnée

Dim_Products

Dimension produits avec hierarchie : Produit > Catégorie

- **ProductKey** : Cle de substitution (PK)
- **ProductID** : Cle naturelle
- **ProductName** : Nom du produit
- **CategoryName** : Nom de la catégorie
- **UnitPrice** : Prix unitaire
- **Discontinued** : Indicateur produit arrêté

- **DataSource** : Origine de la donnee

Dim_Employees

Dimension employees

- **EmployeeKey** : Cle de substitution (PK)
- **EmployeeID** : Cle naturelle
- **FullName** : Nom complet
- **Title** : Titre du poste
- **DataSource** : Origine de la donnee

5.2. Table de Faits

La table de faits contient les mesures quantitatives (metriques) que l'on souhaite analyser. Elle fait le lien entre toutes les dimensions.

Fact_Sales

Table de faits des ventes avec les mesures suivantes :

Cles etrangeres

- **OrderID** : Cle de commande (dimension degeneratee)
- **ProductID** : Reference vers Dim_Products
- **CustomerID** : Reference vers Dim_Customers
- **EmployeeID** : Reference vers Dim_Employees
- **TimeKey** : Reference vers Dim_Time

Mesures

- **SalesAmount** : Montant des ventes (apres remise) - Formule : $\text{UnitPrice} * \text{Quantity} * (1 - \text{Discount})$
- **GrossAmount** : Montant brut (avant remise) - Formule : $\text{UnitPrice} * \text{Quantity}$
- **DiscountAmount** : Montant de la remise - Formule : $\text{GrossAmount} - \text{SalesAmount}$
- **Quantity** : Quantite vendue
- **Freight** : Frais de port
- **DaysToShip** : Delai de livraison en jours

Indicateurs binaires

- **IsHighFreight** : Commande avec freight > 500\$ (KPI requis)
- **IsLateDelivery** : Livraison en retard (ShippedDate > RequiredDate)

6. Fusion des Sources de Donnees

La fusion des donnees est un element cle de ce projet. Elle permet d integrer les contributions des deux sources tout en garantissant la coherence des donnees.




Figure 3 : Comparaison du nombre d enregistrements par source

6.1. Statistiques de fusion

Table	SQL Server	Access 2012	Total fusionne	Commentaire
Customers	91	29 uniques	120	Union avec deduplication
Products	77	19 uniques	96	Prix SQL Server prioritaires
Employees	9	9	9	Memmes employes dans les deux sources
Orders	830	48 uniques	878	Union des commandes
Order Details	2 155	58	2 213	Lignes de details fusionnees

6.2. Exemples de differences traitees

Exemple 1 : Employes manquants

La base Access 2012 ne contient pas les 2 employes les plus recents. Le systeme les integre automatiquement depuis SQL Server.

Exemple 2 : Prix differents

Les prix dans Access sont en moyenne 5% inferieurs a ceux de SQL Server. Le systeme conserve les prix SQL Server, consideres comme plus a jour.

Exemple 3 : Produits discontinues

Certains produits marques comme discontinues dans SQL Server ne le sont pas dans Access. Le systeme conserve l etat SQL Server.

6.3. Regles de fusion

La strategie de fusion suit les regles suivantes :

1. **Union complete** : Tous les enregistrements de SQL Server sont inclus
2. **Ajout des uniques** : Les enregistrements uniques a Access sont ajoutes
3. **Deduplication** : Les doublons sont elimines sur la cle primaire
4. **Priorite SQL Server** : En cas de conflit, SQL Server l emporte
5. **Traçabilité** : Chaque enregistrement conserve sa source d origine

7. Indicateurs Cles de Performance (KPIs)

Le tableau de bord presente les indicateurs cles permettant de suivre la performance de l'entreprise Northwind. Ces KPIs sont calcules a partir des donnees fusionnees du Data Warehouse.



Figure 4 : Indicateurs cles de performance du projet Northwind BI

7.1. KPIs Principaux

Indicateur	Description	Valeur actuelle	Formule de calcul
Chiffre d affaires	Total des ventes (SalesAmount)	\$1 333 929,86	SUM(SalesAmount)
Nombre de commandes	Commandes uniques	870	COUNT(DISTINCT OrderID)
Panier moyen	CA / Nombre de commandes	\$1 533,25	SUM(SalesAmount) / COUNT(DISTINCT OrderID)
Clients actifs	Nombre de clients ayant commande	104	COUNT(DISTINCT CustomerID)

Indicateur	Description	Valeur actuelle	Formule de calcul
Quantite vendue	Total des unites vendues	54259	SUM(Quantity)
Produits vendus	Nombre de produits distincts	79	COUNT(DISTINCT ProductID)

7.2. KPIs Specifiques au projet

Le projet requiert le suivi de deux indicateurs specifiques :

Indicateur	Description	Valeur	Seuil
Frais de port > 500\$	Commandes avec freight eleve	13 commandes	Freight > 500
Livraisons en retard	Commandes livrees apres la date requise	37 commandes	ShippedDate > RequiredDate

7.3. Interpretation des resultats

Analyse du chiffre d affaires

Le chiffre d affaires total de \$1,33 million est genere par 870 commandes, ce qui donne une valeur moyenne de commande de \$1 533. Cette metrique est importante pour evaluer le panier moyen et identifier les opportunités de vente additionnelle.

Analyse des livraisons

Avec 37 commandes livrees en retard (4,25% du total), l entreprise dispose d une bonne performance logistique. Cependant, ces retards peuvent impacter la satisfaction client et meritent une analyse approfondie par pays et par periode.

Analyse des frais de port

Les 13 commandes avec frais de port superieurs a 500\$ representent des cas particuliers qui peuvent indiquer des commandes urgentes, des destinations eloignees ou des produits volumineux.

8. Tableau de Bord et Visualisations

Le projet inclut un tableau de bord interactif développé avec Plotly, permettant d'explorer les données de manière visuelle et intuitive.

8.1. Evolution mensuelle des ventes

Le graphique d'évolution mensuelle montre la saisonnalité des ventes et permet d'identifier les périodes de forte et de faible activité. Cette analyse est essentielle pour la planification des stocks et des ressources.

8.2. Repartition par categorie




Figure 5 : Repartition des ventes par categorie de produits

Les categories les plus performantes sont :

- **Boissons** : 22,9% du CA (categorie leader)
- **Produits laitiers** : 17,8% du CA

8.3. Analyse géographique




Figure 6 : Top 10 pays par chiffre d'affaires

L analyse géographique revele que :

- **Les Etats-Unis** representent plus de 39% du CA mondial
- **L Allemagne** est le deuxieme marche avec 13,5% du CA
- **La France** complete le podium avec 11,2% du CA
- 21 pays sont desservis au total

8.4. Top produits

L analyse des produits les plus vendus permet d identifier les produits phares et d optimiser les strategies de marketing et d approvisionnement.

8.5. Commandes avec freight eleve

Cette visualisation permet d identifier les commandes necessitant une attention particuliere en raison de leurs couts de transport eleves.

8.6. Livraisons en retard

Cette analyse met en evidence les problemes logistiques et permet de prendre des mesures correctives pour ameliorer la satisfaction client.

9. Choix Techniques

Les choix techniques ont été guidés par les contraintes du projet, la disponibilité des outils et les meilleures pratiques du domaine BI.

9.1. Langage de programmation

Choix	Justification
Python	Langage populaire pour la BI, riche en bibliothèques, syntaxe claire, large communauté

9.2. Bibliothèques utilisées

Bibliothèque	Utilisation	Justification
pandas	Manipulation de données	Standard de l'industrie pour l'analyse de données en Python
pyodbc	Connexion SQL Server & Access	Driver ODBC officiel Microsoft, compatible avec les deux sources
sqlite3	Data Warehouse local	Léger, portable, SQL standard, pas de serveur requis
plotly	Visualisations interactives	Graphiques web modernes, interactivité, export HTML
matplotlib / seaborn	Visualisations statiques	Export en images pour le reporting
numpy	Calculs numériques	Performances et opérations vectorisées

9.3. Architecture de stockage

Composant	Choix	Justification
Data Warehouse	SQLite	Simple à déployer, compatible avec pandas, suffisant pour la volumétrie du projet

Composant	Choix	Justification
Format d export	CSV (UTF-8)	Universel, lisible par tous les outils d analyse
Format de visualisation	HTML (Plotly)	Interactif, accessible via navigateur, facile a partager

9.4. Modele de donnees

Aspect	Choix	Justification
Schema	Schema en etoile (Star Schema)	Simplicité de requetes, bonnes performances pour OLAP
Cles de dimension	Cles de substitution (surrogate keys)	Indépendance du système source, meilleure performance
Traçabilité	Champ DataSource	Identification de l origine pour audit et qualité

9.5. Gestion des erreurs et logging

Le système implémente une gestion robuste des erreurs :

- **Fallback CSV** : En cas d indisponibilité des bases de données, le système utilise des fichiers CSV
- **Logging** : Toutes les opérations sont tracées dans un fichier de log (etl_log.txt)
- **Gestion des exceptions** : Les erreurs sont capturées et ne bloquent pas le processus
- **Validation** : Les données sont validées à chaque étape du pipeline

10. Conclusion et Perspectives

Conclusion

Ce projet de Business Intelligence a permis de mettre en oeuvre une solution complete d integration de donnees heterogenes, depuis l extraction jusqu a la restitution, en passant par la transformation et le stockage dans un Data Warehouse.

Reussites du projet

- **Integration reussie** : Fusion de 2 sources heterogenes (SQL Server + Access) avec 3 196 enregistrements fusionnes
- **Data Warehouse operationnel** : Schema en etoile implemente avec 4 dimensions et 1 table de faits
- **KPIs pertinents** : 8 indicateurs cles permettant de piloter l activite commerciale
- **Gestion des incoherences** : Strategies de resolution implementees pour garantir la qualite des donnees
- **Traçabilité assurée** : Chaque enregistrement conserve la trace de son origine
- **Tableau de bord interactif** : Visualisations modernes et intuitives

Competences developpees

- Conception et implementation de pipelines ETL
- Modelisation de Data Warehouses (schema en etoile)
- Gestion de l integration de sources heterogenes
- Developpement de tableaux de bord analytiques
- Calcul et suivi d indicateurs de performance

10.1. Limites et contraintes

Le projet presente certaines limites qui pourraient etre ameliorees dans une version future :

- **Volumetrie** : Le systeme est concu pour des volumes modestes. Pour des millions de lignes, il faudrait envisager une base de donnees plus performance (PostgreSQL, SQL Server)
- **Automatisation** : Le processus ETL est manuel. Une automatisation (planification) serait souhaitable en production
- **Monitoring** : Le suivi du processus ETL pourrait etre renforce avec des alertes en cas d erreur
- **Securite** : Les identifiants de connexion sont en clair dans le code. Il faudrait utiliser des variables d environnement
- **Tests** : Le projet manque de tests automatises pour garantir la qualite

10.2. Perspectives d evolution

Plusieurs ameliorations pourraient etre apportees au projet :

A court terme

- **Automatisation** : Planification du processus ETL avec un orchestrateur (Apache Airflow, cron)
- **Alerting** : Notifications en cas d erreur ou de degradation des performances
- **Tests unitaires** : Ajout de tests pour valider chaque etape du pipeline
- **Documentation** : Generation automatique de la documentation (docstring, Sphinx)

A moyen terme

- **Cubes OLAP** : Implementation de cubes avec Mondrian ou SSAS pour des analyses multidimensionnelles avancees
- **Data Quality** : Ajout de regles de qualite des donnees avec reporting des anomalies
- **Machine Learning** : Prediction des ventes, clustering des clients, detection de fraude
- **API REST** : Exposition des donnees via une API pour integration avec d autres systemes

A long terme

- **Cloud** : Migration vers une architecture cloud (AWS, Azure, GCP) pour la scalabilite
- **Big Data** : Integration avec Spark ou Hadoop pour le traitement de grandes volumetries
- **Real-time** : Passage a un traitement en temps reel avec Apache Kafka, Apache Storm

- **Self-Service BI** : Outils permettant aux utilisateurs metiers de creer leurs propres analyses

10.3. Bilan final

Ce projet a permis de mettre en pratique l'ensemble des concepts enseignes dans le module Technologies Business Intelligence :

- Compréhension des enjeux de l'intégration de données hétérogènes
- Maîtrise des techniques ETL (Extract, Transform, Load)
- Conception de modèles de Data Warehouse (schéma en étoile)
- Développement de tableaux de bord analytiques
- Calcul et interprétation d'indicateurs de performance

Cette expérience constitue une base solide pour l'accompagnement de projets BI en entreprise, où la problématique de l'intégration de sources multiples est récurrente.

Merci pour votre attention.
BOUMEDIENE Noufel